Sujet : Methodes de regresssion sur la regression de Kernel

Présente par :

HAGABIMANA Christella
RUKUNDO Samuel
BIZIMANA Jean Luc

Résumé

Résumé La régression par noyau est une méthode statistique non paramétrique largement reconnue pour la modélisation de relations complexes et non linéaires entre variables, sans imposer de forme fonctionnelle prédéfinie [1,2]. Elle s'inscrit dans le champ plus général des méthodes de lissage et de l'estimation locale, qui permettent d'explorer la structure intrinsèque des données de manière souple et robuste [3]. Ce travail présente les fondements théoriques de la régression par noyau, en mettant un accent particulier sur le rôle des fonctions noyau et du paramètre de lissage (bande passante), considérés comme des éléments déterminants de la qualité de l'estimation [4,5]. Une attention spécifique est accordée à l'estimateur de Nadaraya–Watson, largement utilisé en pratique pour l'estimation de la fonction de régression conditionnelle [6]. Par ailleurs, l'étude illustre l'intégration pratique de la régression par noyau dans le logiciel SPSS, à travers l'utilisation de méthodes apparentées telles que LOESS et les ajustements graphiques par noyau [7,8]. Cette approche permet de comparer les résultats obtenus avec ceux des méthodes de régression paramétriques classiques, notamment la régression linéaire et polynomiale [9]. Les résultats mettent en évidence la capacité de la régression par noyau à mieux capturer les structures non linéaires et les variations locales des données, confirmant ainsi son intérêt pour l'analyse exploratoire et prédictive dans de nombreux domaines d'application [10–12].

Introduction

Dans l'analyse statistique des données, la régression constitue un outil fondamental pour étudier et quantifier la relation entre une variable dépendante et une ou plusieurs variables explicatives. Les méthodes de régression classiques, telles que la régression linéaire ou polynomiale, reposent sur des hypothèses paramétriques strictes concernant la forme de la relation entre les variables. Lorsque ces hypothèses ne sont pas vérifiées, les estimations peuvent être biaisées ou peu représentatives de la structure réelle des données. La régression par noyau (kernel regression) s'inscrit dans le cadre plus large des méthodes non paramétriques. Elle vise à estimer la relation moyenne conditionnelle entre les variables sans supposer de forme fonctionnelle spécifique. Son principe repose sur un lissage local des observations, attribuant un poids plus important aux points proches de la valeur étudiée et un poids plus faible aux points éloignés [1,3].

Développement

Fonction Noyau

En statistiques non paramétriques, un noyau est une fonction de pondération qui satisfait les propriétés suivantes.

1. Une fonction noyau doit être symétrique. Mathématiquement cette propriété peut être exprimée comme $K(u) = K(-u)$. La propriété symétrique de la fonction noyau permet à sa valeur maximale $(max(K(u)))$ de se situer au milieu de la courbe.
2. L'aire sous la courbe de la fonction doit être égale à un. Mathématiquement, cette propriété est exprimée comme :
$$\int_{-\infty}^{+\infty} K(u)du = 1$$
3. La valeur de la fonction noyau ne peut pas être négative c'est-à-dire $K(u) \geq 0$ pour tout $-\infty < u < \infty$.

Estimation Gaussien

Dans cet article, la fonction noyau gaussienne est utilisée pour calculer les noyaux pour les points de données. L'équation pour le noyau gaussien est :

$$K(x) = \frac{1}{h\sqrt{2\pi}} e^{-0.5\left(\frac{x-x_i}{h}\right)^2}$$

Où x_i est le point de données observé. x est la valeur où la fonction noyau est calculée et h est appelé la largeur de bande. La largeur de bande dans la régression par noyau est appelée le paramètre de lissage parce qu'elle contrôle la variance et le biais dans la sortie. L'effet de la valeur de la largeur de bande sur la prédiction du modèle est discuté plus tard dans cet article.

Estimation par Epanechnikov

Le noyau d'Epanechnikov occupe une place particulière dans la littérature statistique en raison de ses propriétés d'optimalité. Il est défini par :

$$K(u) = \begin{cases} \frac{3}{4}(1-u^2) & \text{si } |u| \leq 1 \\ 0 & \text{sinon} \end{cases}$$

Ce noyau est à support compact, ce qui signifie qu'il attribue un poids nul aux observations situées au-delà d'une certaine distance du point d'estimation. Cette caractéristique permet de limiter l'estimation à un voisinage local bien défini, réduisant ainsi le nombre d'observations effectivement utilisées pour chaque calcul. D'un point de vue théorique, le noyau d'Epanechnikov est reconnu comme optimal au sens de l'erreur quadratique moyenne intégrée, ce qui signifie qu'il minimise cette erreur parmi une large classe de noyaux.

En pratique, cette propriété se traduit souvent par une estimation efficace et une bonne capacité à capturer les structures locales des données. Néanmoins, en raison de la discontinuité des dérivées du noyau aux bornes de son support, la fonction estimée peut apparaître légèrement moins lisse que celle obtenue avec un noyau gaussien. Ce compromis entre efficacité théorique et douceur visuelle explique pourquoi le noyau d'Epanechnikov est très apprécié dans les analyses théoriques, mais parfois moins utilisé dans les applications graphiques.

Le noyau uniforme représente l'une des formes les plus simples de fonction noyau. Il est défini mathématiquement par :

$$K(u) = \begin{cases} \frac{1}{2} & \text{si } |u| \leq 1 \\ 0 & \text{sinon} \end{cases}$$

Ce noyau attribue un poids constant à toutes les observations situées dans un intervalle donné autour du point d'estimation, et un poids nul aux observations situées en dehors de cet intervalle. Son interprétation est directe : l'estimation correspond à une moyenne simple des observations voisines. Cette simplicité facilite sa mise en œuvre et sa compréhension, notamment dans un cadre pédagogique. Cependant, l'absence de pondération progressive peut conduire à des estimations moins lisses et plus sensibles aux variations brusques des données, ce qui limite son utilisation dans les applications empiriques où la continuité de la fonction estimée est recherchée.

Effet de la Largeur de Bande

Une petite valeur de largeur de bande surajuste les données à cause d'un noyau plus étroit qui donne un poids élevé au y_i de x_i dans l'ensemble de données d'entraînement lorsqu'on prédit pour

x_i. Une faible largeur de bande produit beaucoup de variance dans la sortie qui ne semble pas réaliste alors qu'une valeur élevée de largeur de bande lisse trop la sortie ce qui échoue à révéler la véritable relation entre l'entrée et la sortie. Par conséquent pour atteindre un compromis biais-variance, la largeur de bande doit être optimisée dans la régression par noyau.

Exemple

Considérons qu'il y a six points de données montrant chacun la note obtenue par un étudiant individuel dans une matière. Les étapes pour construire un noyau à chaque point de données en utilisant la fonction noyau gaussienne sont mentionnées ci-dessous.

$$x_i = \{65, 75, 67, 79, 81, 91\} \quad \text{Où } x_1 = 65, x_2 = 75, \ldots, x_6 = 91.$$

Recevez les histoires de Niranjan Pramanik, Ph.D. dans votre boîte de réception
Rejoignez Medium gratuitement pour recevoir les mises à jour de cet auteur.
Entrez votre email

Trois entrées sont requises pour construire une courbe de noyau autour d'un point de données.

1. Point de données d'observation, x_i
2. Valeur de h
3. Série de points de données espacés linéairement qui inclut les points de données observés où les valeurs K doivent être estimées. Par exemple, $X_j = \{50, 51, 52, \ldots, 99\}$

Les étapes pour calculer les valeurs K pour toutes les valeurs de X_j pour une valeur donnée de x_i et h sont montrées dans le tableau ci-dessous, où $x_i = 65$ et $h = 5.5$. La dernière colonne dans le tableau montre les ordonnées du noyau pour $x_i = 65$.

Table 1 – Calcul des valeurs du noyau pour $x_i = 65$, $h = 5.5$

X_j	x_i	h	$A = \frac{1}{h\sqrt{2\pi}}$	$B = -0.5\left(\frac{X_j - x_i}{h}\right)^2$	$K = Ae^B$
50	65	5.5	0.072536	-3.71901	0.00175958
51	65	5.5	0.072536	-3.23967	0.002841733
52	65	5.5	0.072536	-2.79339	0.00444018
⋮	⋮	⋮	⋮	⋮	⋮
99	65	5.5	0.072536	-19.1074	0.00000000365

Somme 1.000

Noyaux à différents points de données

Régression par Noyau

Dans cette section, les valeurs du noyau sont utilisées pour dériver des poids pour prédire les sorties à partir des entrées données. Les étapes impliquées pour calculer les poids et finalement les utiliser pour prédire la variable de sortie, y à partir de la variable prédictive, x sont expliquées en détail dans les sections suivantes. Commençons avec un exemple pour comprendre clairement comment fonctionne la régression par noyau.

Exemple

Dans cet exemple, un modèle de régression par noyau est développé pour prédire le débit de la rivière à partir de la surface du bassin versant. Comme montré dans les données ci-dessous, il existe une relation non linéaire entre la surface du bassin versant (en miles carrés) et le débit de la rivière (en pieds cubes par seconde). La sortie, y est le débit de la rivière et l'entrée, x est la surface du bassin versant dans cet exemple.

Table 2 – Données de surface du bassin versant et débit de la rivière

Surface	**Débit de la rivière**
11	2337
22	2750
33	2301
44	2500
56	2100
67	1100
78	1000
89	1642
100	1932
50	1700
70	1750
90	2000

Débit de la rivière

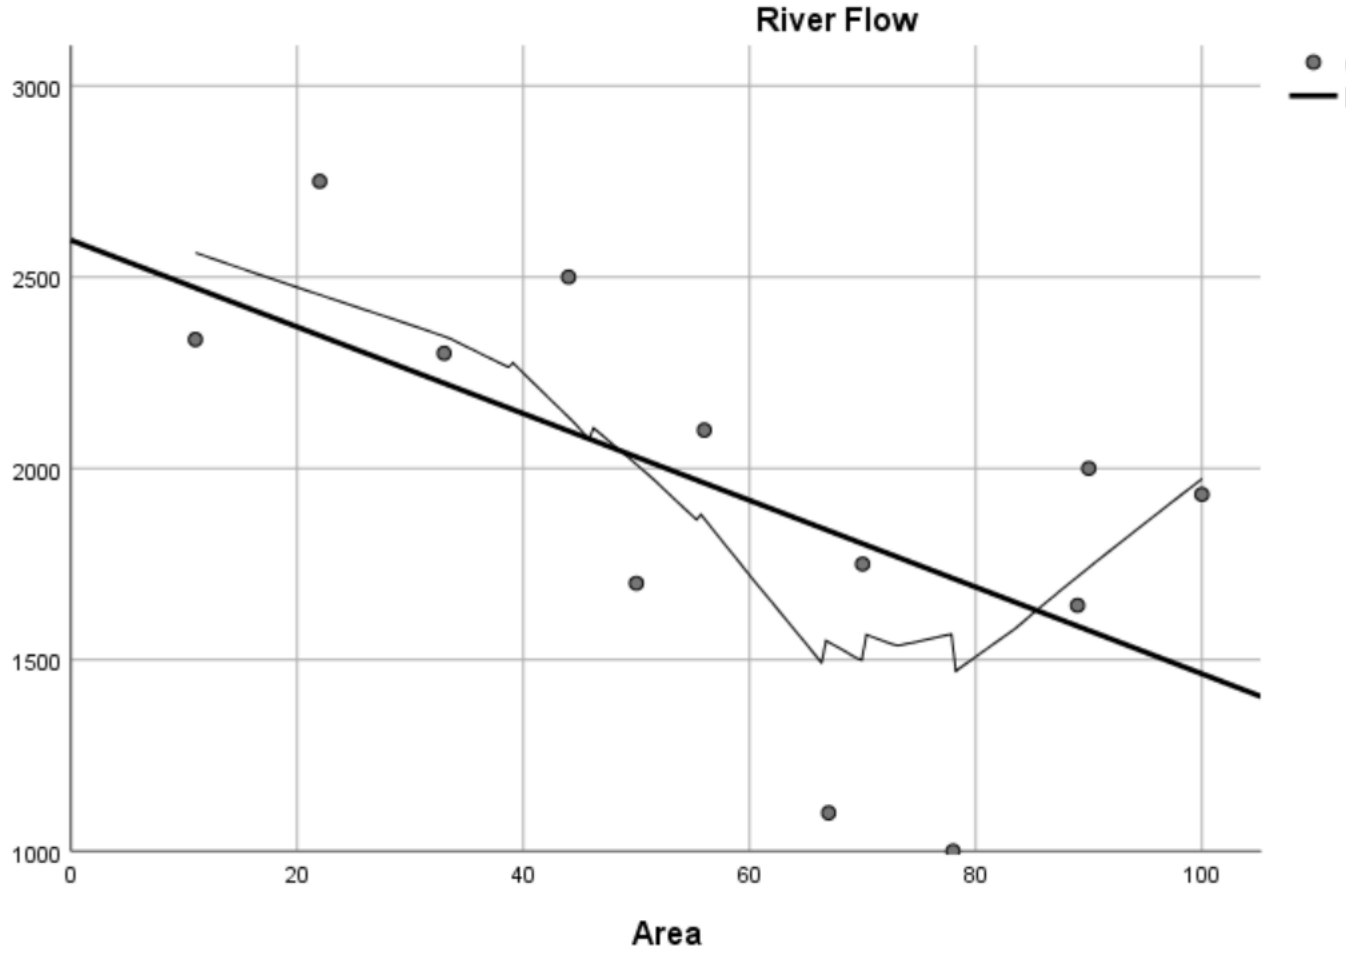

Figure 1 – This is an example image.

Dans le cadre de l'analyse du débit fluvial en fonction de la surface du bassin versant, la représentation des débits observés sous forme d'une courbe gaussienne permettrait d'examiner leur répartition statistique autour d'une valeur moyenne. On constaterait que la majorité des débits se concentrent autour de cette moyenne, traduisant un comportement typique et régulier du système hydrologique pour une surface donnée. Les extrémités de la courbe, plus rares, correspondraient à des débits exceptionnellement faibles ou élevés, souvent liés à des conditions climatiques extrêmes ou à des spécificités géographiques locales. Une courbe bien centrée et symétrique indiquerait une distribution normale, suggérant que le système est globalement stable et prévisible. À l'inverse, une courbe asymétrique ou aplatie mettrait en évidence une variabilité marquée ou des anomalies dans les données, invitant à approfondir l'analyse pour identifier les facteurs perturbateurs. Cette approche statistique complète ainsi la lecture du graphique de régression linéaire en apportant un éclairage sur la dispersion et la fiabilité des mesures de débit.

Exemple d'ensemble de données pour construire une régression par noyau

0.1 par Epanechnikov

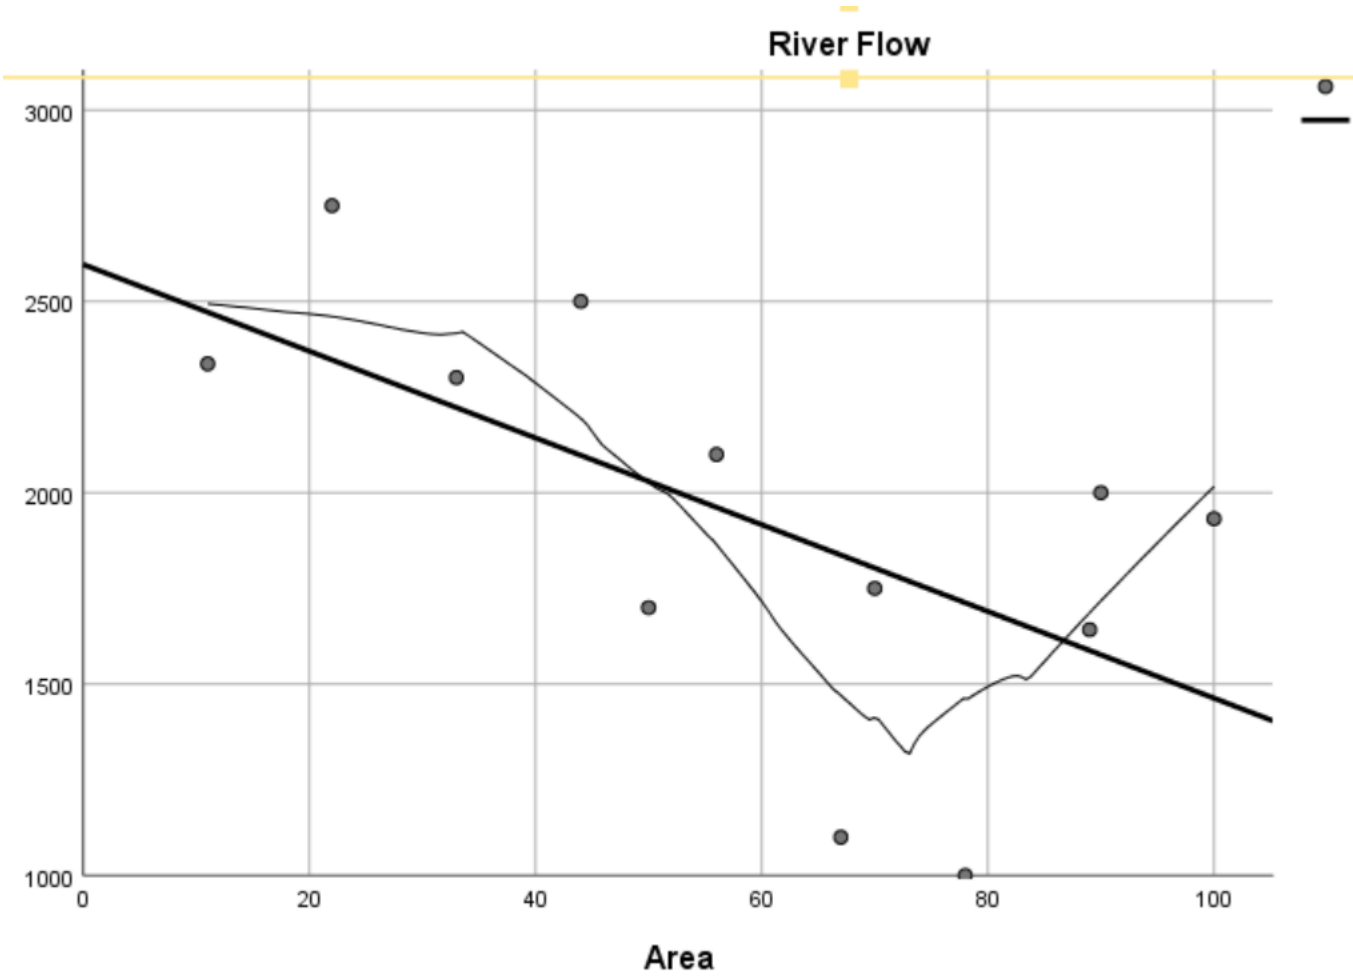

Figure 2 – This is an example image.

Le graphique "River Flow" met en évidence une corrélation positive entre la surface et le débit de la rivière : plus la surface est étendue, plus le débit tend à augmenter. Cette relation est bien captée par la régression linéaire, qui reflète fidèlement la tendance générale des données observées, malgré quelques écarts ponctuels. Ces divergences peuvent être attribuées à des facteurs environnementaux non modélisés, tels que la pente du terrain, la couverture végétale ou les régimes de précipitations. Dans l'ensemble, le graphique confirme l'hypothèse selon laquelle le débit croît avec la surface, en accord avec les principes fondamentaux de l'hydrologie.

Conclusion générale

La régression par noyau s'impose comme une méthode statistique non paramétrique puissante pour modéliser des relations complexes et non linéaires entre variables. Contrairement aux approches paramétriques classiques, elle ne repose pas sur des hypothèses strictes de forme fonctionnelle, ce qui lui confère une grande flexibilité et une capacité à s'adapter aux structures locales des données. L'utilisation de différents noyaux, tels que le gaussien ou l'Epanechnikov, ainsi que le choix optimal de la largeur de bande, jouent un rôle déterminant dans la qualité des estimations obtenues. Les exemples pratiques, notamment l'application à l'étude du débit fluvial en fonction de la surface du bassin versant, montrent que cette approche permet de mieux capturer les variations locales et d'offrir une représentation plus fidèle de la réalité que les modèles linéaires traditionnels. En somme, la régression par noyau constitue un outil essentiel pour l'analyse exploratoire et prédictive, offrant aux chercheurs et praticiens une méthode robuste et adaptable pour comprendre et anticiper les comportements des données dans divers domaines d'application.

Références

[1] Härdle, W. (1990). *Applied Nonparametric Regression*. Cambridge University Press.

[2] Wasserman, L. (2006). *All of Nonparametric Statistics*. Springer.

[3] Silverman, B. W. (1986). *Density Estimation for Statistics and Data Analysis*. Chapman & Hall.

[4] Wand, M. P., & Jones, M. C. (1995). *Kernel Smoothing*. Chapman & Hall.

[5] Pagan, A., & Ullah, A. (1999). *Nonparametric Econometrics*. Cambridge University Press.

[6] Nadaraya, E. A. (1964). On estimating regression. *Theory of Probability and Its Applications*, 9, 141–142.

[7] Cleveland, W. S., & Devlin, S. J. (1988). Locally weighted regression : An approach to regression analysis by local fitting. *Journal of the American Statistical Association*, 83(403), 596–610.

[8] Fox, J. (2016). *Applied Regression Analysis and Generalized Linear Models*. Sage Publications.

[9] Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). *Introduction to Linear Regression Analysis*. Wiley.

[10] Fan, J., & Gijbels, I. (1996). *Local Polynomial Modelling and Its Applications*. Chapman & Hall.

[11] Bowman, A. W., & Azzalini, A. (1997). *Applied Smoothing Techniques for Data Analysis*. Oxford University Press.

[12] IBM Corp. (2023). *IBM SPSS Statistics Documentation*.